

别重训——对齐：通过表征对齐将自回归语言模型适配到扩散语言模型

弗雷德·张志鹏* 杜克大学

亚历克西斯·福克斯 杜克大学


安如 R. 张, 杜克大学

亚历山大·通 AI THYRA


摘要

扩散语言模型 (DLM) 近期展现出与标准自回归 (AR) 模型互补的能力, 尤其体现在非顺序生成和双向编辑方面。尽管最近的工作表明, 预训练的自回归检查点可以转换为扩散语言模型, 但现有方法主要通过持续的去噪训练, 并结合目标函数和注意力层级的修改来传递参数。我们则进一步提出: 能否在 AR→DLM 转换过程中, 显式保留通过下一个词预测学到的内部表示几何结构? 我们的假设是, AR 预训练所学到的大量语义结构可以跨生成顺序迁移, 因此 DLM 训练应被视为重新学习解码路径, 而不是重新学习语言表示。为此, 我们提出 REPR-ALIGN, 这是一种

Representation Alignment 目标函数, 它使双向掩码扩散模型能够复用来自具有相同架构的预训练 AR 模型的表示。具体而言, 我们在优化标准掩码去噪目标的同时, 使用余弦相似度在每一层将 DLM 的隐藏状态与冻结的 AR 模型对齐。这种简单的对齐方式——除注意力掩码外不引入适配器, 也不做任何架构改动——在我们的设置中最高可带来 $4\times$ 的训练加速, 并且在低数据场景下尤为有效。我们的结果表明, 语言表示与生成顺序无关, 具有普适性; 而表示对齐可能成为训练扩散语言模型的一种新的首选技术。代码见 <https://github.com/pengzhangzhi/Open-dLLM>。



(a) Adaptation speed.



(b) Public DLM frontier.

图 1：不要重新训练——要对齐。左：REPR-ALIGN 在 HumanEval pass@10 上持续加速 AR→DLM 适配, 在早期转换阶段始终优于 AR 微调 and 从零开始训练。右：生成的 oDLM 在公开 DLM 中实现了更优的 HumanEval pass@10 与训练数据之间的权衡。

*Correspondence to: zhangzhi.peng@duke.edu




图2：我们的方法 REPR-ALIGN 概览：通过切换到双向注意力并使用掩码去噪目标进行训练，我们将预训练的自回归（AR）Transformer 适配为掩码扩散语言模型（DLM），同时将逐层隐藏状态锚定到冻结的 AR 主干。

1 引言

大型语言建模中的主导范式长期以来一直是自回归（AR）序列建模。通过将联合概率分布分解为条件概率的乘积，GPT 和 Qwen 等模型已展现出强大的通用生成能力 [Radford et al., 2019, Achiam et al., 2023, Touvron et al., 2023]。近年来，扩散语言模型（DLMs）作为文本生成的一种替代形式出现，涵盖了在嵌入空间上的连续扩散、离散吸收态扩散、基于似然的扩散语言模型、掩码扩散语言模型以及大规模 DLMs [Li et al., 2022, Austin et al., 2021a, Gulrajani and Hashimoto, 2023, Sahoo et al., 2024, Nie et al., 2025b, Ye et al., 2025]。通过将生成建模为任意顺序解码 [Sohl-Dickstein et al., 2015, Ho et al., 2020, Yang et al., 2019, Ghazvininejad et al., 2019]，DLMs 天然支持非从左到右的行为，例如补全（infilling）和迭代细化 [Sahoo et al., 2024, Gulrajani and Hashimoto, 2023, Chang et al., 2022]。尽管具有这些优势，扩展 DLMs 仍然代价高昂。理论上，DLMs 学习的是 $\sum_{t=1}^T$ 条路径来生成一个序列，而 AR 模型只需一次从左到右生成，因此需要多 $\sum_{t=1}^T$ 倍的计算量。虽然近期已有若干方法通过从预训练的 AR 检查点初始化，或将 AR 模型转换为 DLMs 来降低这一成本 [Gong et al., 2025a, Ye et al., 2025, Fu et al., 2025]，但现有的转换方案大多通过持续去噪训练、注意力模式修改或采样约定来复用 AR 参数。它们并未显式约束转换后的 DLM 去保持 AR 模型的内部表示几何结构。

本文中，我们质疑将 AR 和 DLM 视为两种彼此分离的范式的必要性。我们从一个简单的观点出发：语言生成中最困难的部分是学习语言表征——即数据的语义和句法结构——而不是绑定到某种特定的生成顺序。自回归预训练已经学到了强大的内部特征，用于组织这种结构。既然如此，训练扩散语言模型就不应当需要从头重新学习语言表征。相反，剩下的工作主要是机械性的：将这些已有特征适配到一个迭代式的任意顺序解码器中。这就把 DLM 训练从表征学习重构为一个对齐问题，在这个问题中，我们复用 AR 主干来提供表征，并训练扩散机制在同一特征空间中运行，同时支持任意顺序生成。

为了验证这一假设，我们首次应用 *Representation Alignment* [Yu et al., 2025, Singh et al., 2025, Wu et al., 2025, Jiang et al., 2025]，将一个预训练的 AR Transformer 以最简化的方式适配为掩码扩散语言模型（图 2）。我们的设置使用两个架构相同的模型：（i）一个带因果注意力的预训练 AR 模型，以及（ii）一个从 AR 权重初始化但采用双向注意力的相同架构。在训练过程中，我们随机遮蔽一个序列，并优化 DLM 去预测被遮蔽的标记。同时，我们输入干净序列

将其输入冻结的 AR 模型（在因果注意力下采用 teacher-forced 方式）并提取其在每一层的隐藏状态。由于这两个网络共享相同的层结构和隐藏维度，我们可以通过逐层的余弦相似度损失直接对齐它们的中间表示，而无需引入适配器或额外参数。直观地说，AR 模型提供了一个稳定的表征锚点，而扩散训练则被简化为学习一种在该锚定特征空间中运行的任意顺序解码机制。该方法的设计尽可能减少改动，从而使任何收益都可归因于 AR 特征的复用，而非架构修改或繁重的微调。

我们的实验支持通过对齐实现复用的观点：表示对齐将 AR→DLM 转换变成了一个在很大程度上是机械式的适配问题，而不是重新学习语言表征。在 HumanEval 上，对齐提升了转换质量，而且收益会随着模型规模增大而增长（图 3），使 pass@10 在 0.6B 时从 24.9 提升到 31.0，在 1.7B 时从 31.1 提升到 40.5。除了质量提升之外，对齐还通过选择性训练显著降低了转换成本（图 4），并且在 0.8B-token 的 *tiny* 子集下仍然有效（图 5）。作为规模扩展验证，我们使用相同的保留表征转换配方训练了一个 4B 的 oDLM。与 Dream-7B 相比，后者是一个强大的公开 DLM，同样建立在 AR 初始化之上，oDLM 在 HumanEval 系列 pass@10 的权衡上表现更优（图 1b 和表 1）：尽管参数更少、数据和算力预算也显著更轻，它仍分别将 HumanEval 和 HumanEval+ 的 pass@10 提高了 2.39 和 2.40 个百分点。

贡献。我们的贡献总结如下：

- 我们将表征保持确定为 AR→DLM 转换中缺失的一项关键要素。我们并非仅仅从一个 AR 检查点进行初始化，而是在掩码去噪训练期间，显式地将 DLM 学生模型锚定到冻结的 AR 模型逐层隐藏状态几何结构上。
- 我们提出了一种简单的表征保持转换方案，除将因果注意力切换为双向注意力外，无需适配器或架构改动。在不同模型规模下，表征对齐都能提升转换质量和样本效率，而且模型越大，收益越明显。
- 我们表明，AR→DLM 转换并非本质上就需要大量数据或参数更新。借助表征对齐，在相同步数预算下，使用 0.8B 词元子集训练的效果甚至可以优于使用完整 50B 词元流训练的效果；同时，冻结嵌入层和 MLP 模块可在不降低质量的情况下将吞吐量提升至 $\sim 2\times$ 倍。
- 作为规模扩展验证，我们使用同样的方案训练了一个 4B 的 oDLM。与 Dream-7B（另一种也利用 AR 初始化的强大公开 DLM）相比，oDLM 在 HumanEval 和 HumanEval+ pass@10 上分别提升了 2.39 和 2.40 个百分点，同时使用了更小的骨干模型以及显著更轻的数据与计算预算。

2 相关工作

扩散语言模型。扩散语言模型涵盖了嵌入上的连续扩散、离散类别扩散、基于似然的扩散语言模型以及掩码扩散语言模型 [Li et al., 2022, Austin et al., 2021a, Gulrajani and Hashimoto, 2023, Sahoo et al., 2024, Nie et al., 2025a]。近期的大规模系统，如 LLaDA 和 Dream，表明掩码扩散可以在十亿参数规模上支持指令遵循、推理和代码生成 [Nie et al., 2025b, Ye et al., 2025]。这些进展使 DLM 成为自回归生成的一个严肃替代方案，但具有竞争力的 DLM 仍然需要大量针对扩散的优化。我们在附录 A.1 中对 DLM 的形式进行了更详细的讨论。

将自回归模型适配为扩散语言模型。越来越多的工作通过将预训练的 AR 检查点转换为去噪模型 [Gong et al., 2025a, Ye et al., 2025, Xie et al., 2025, Fu et al., 2025, Xue et al., 2025]，从而避免从头训练 DLM。这些方法表明 AR 检查点是很强的初始化，但它们主要是在调整目标函数、掩码过程、注意力模式或采样约定。相比之下，我们的工作通过将双向 DLM 学生与一个冻结的、同架构的 AR 教师对齐，显式保留了 AR 模型的内部表示几何，如第 3.3 节所形式化说明的那样。附录 A.2 和 A.3 给出了更完整的比较

使用 AR→DLM 转换、任意顺序生成、迭代掩码解码和路径规划方法。

生成模型的表征对齐。表征对齐最近通过将生成模型的隐藏状态与强大的预训练编码器的表征进行匹配，加速了扩散训练 [Yu et al., 2025, Singh et al., 2025, Wu et al., 2025, Jiang et al., 2025]。我们的设定在教师模型和目的上都不同：教师不是外部编码器，而是正在被转换的那个精确 AR 模型，其分词器、架构、隐藏维度和初始化都与 DLM 学生模型相同。因此，对齐在机制适配过程中起到的是表征保留的作用，而不是从另一个模型导入特征；公式 (2) 给出了精确的目标。第 A.4 节进一步展开了这一区别。

3 方法

我们研究这个问题：*are representations learned by next-token prediction sufficient for masked denoising generation?*

为了隔离这一因素，我们保持架构不变，只修改扩散式去噪所必需的部分。我们的方法实例化了两个参数配置和维度完全相同的 transformer：一个具有因果注意力的预训练自回归 (AR) 模型，以及一个具有双向注意力的掩码扩散模型。随后，我们使用标准的掩码预测目标来训练扩散模型，同时加入一个单层的表示对齐损失，以复用 AR 模型的内部特征。算法 1 总结了整体转换流程。这里不引入适配器或辅助模块。下面的四项设计选择直接对应于第 4.1 节中的实验设置以及第 4.3 节中的消融实验。

算法 1 使用逐层表示对齐进行 REPR-ALIGN AR→DLM 转换。

```
# f_AR: frozen AR teacher (causal attention), params theta_AR
# f_D : DLM student (bidirectional attention), params theta
# theta <- theta_AR; f_D differs only by attention mask (causal -> bidir)

theta = theta_AR
freeze(f_AR); f_AR.eval()

for x in data_stream:
    # x: [B, n] clean tokens
    r = Uniform(0, 1)
    # mask ratio (per sequence)
    M = sample_positions(x, r)
    x_tilde = x.clone(); x_tilde[M] = mask_id # corrupted input

    # student denoising pass (bidirectional)
    logits, H_D = f_D(x_tilde, bidir=True, output_hidden_states=True)

    # teacher anchor pass (causal) on clean x
    with no_grad():
        _, H_AR = f_AR(x, causal=True, output_hidden_states=True)

    # masked denoising loss (shift logits by one token;)
    loss_diff = CE( shift_logits_1(logits)[M], x[M] )

    # layer-wise cosine alignment on hidden states
    loss_align = (1 - cos(H_D, H_AR)).mean()

    loss = loss_diff + lambda_align * loss_align
    step_optimizer(theta, loss)
```

3.1 两个模型，相同架构

设 $x = (x_1, \dots, x_n) \in \mathcal{V}^n$ 为一个 token 序列，并令 $\mathcal{V}$ 包含一个特殊的 mask token (M)。我们定义：(i) 一个自回归 transformer $f_{AR}(\cdot; \theta_{AR})$ ，其采用 *causal* 注意力掩码，通过下一个 token 预测进行预训练；以及 (ii) 一个扩散 transformer $f_D(\cdot; \theta)$ ，其采用 *bidirectional* 注意力。关键的是， f_{AR} 和 f_D 共享相同的层结构和隐藏维度 d ；唯一的架构差异是注意力掩码。我们在整个训练过程中保持 θ_{AR} 冻结。实际上，我们从 θ_{AR} 初始化 θ ，并将注意力掩码从因果式切换为双向式，这样任何收益都可以归因于机制适配，而不是新的容量。

设 $h_{\text{AR}}^{(\ell)}(x) \in \mathbb{R}^{n \times d}$ 和 $h_{\text{D}}^{(\ell)}(x) \in \mathbb{R}^{n \times d}$ 表示两个模型在第 $\ell \in \{1, \dots, L\}$ 层的隐藏状态。该匹配转换设计在第 4.1 节和第 4.2 节中的固定预算协议下进行评估。

3.2 掩码扩散目标

我们将 f_{D} 训练为一个掩码去噪器。我们采样一个掩码集合 $M \subseteq \{1, \dots, n\}$ ，并通过将 x_i 替换为 $\langle M \rangle$ 来构造一个损坏输入 $\tilde{x}$ ，用于 $i \in M$ 。扩散模型在以 $\tilde{x}$ 为条件的情况下预测被掩码的标记，并且我们只在被掩码的位置上优化交叉熵：

$$\mathcal{L}_{\text{diff}}(\theta) = \mathbb{E}_{x, M} \left[\sum_{i \in M} \text{CE}(p_{\theta}(\cdot | \tilde{x})_i, x_i) \right], \quad (1)$$

其中， $p_{\theta}(\cdot | \tilde{x})_i$ 是扩散模型在位置 i 处预测的分布。这个去噪目标是第 4.1 节中基线模型和对齐模型共用的训练损失。

移位约定。为了与从 AR 检查点继承的下一个 token 索引约定保持一致，我们采用 AR $\rightarrow$ DLM 适配中使用的标准移位操作：学生在位置 i 生成 logits，在计算去噪交叉熵以及采样过程中，都会先向前平移一个位置。我们对基线模型和对齐模型都使用相同的移位约定；实现细节见 B.1 节。

3.3 分层表示对齐

为复用 AR 特征，我们在因果注意力下对 *clean* 序列 x 运行一个冻结的自回归教师模型，并将消耗受损 $\tilde{x}$ 、在双向注意力下工作的扩散学生模型锚定到教师的隐藏状态。由于这两个网络共享相同的架构和隐藏维度，我们无需适配器即可直接对齐它们逐层的表示。

设 $h_{\text{AR}}^{(\ell)}(x) \in \mathbb{R}^{n \times d}$ 表示在给定干净 x 时第 ℓ 层的教师隐藏状态，设 $h_{\text{D}}^{(\ell)}(\tilde{x}) \in \mathbb{R}^{n \times d}$ 表示在给定被破坏的 $\tilde{x}$ 时的学生隐藏状态。我们最小化余弦距离损失：

$$\mathcal{L}_{\text{align}}(\theta) = \frac{1}{L} \sum_{\ell=1}^L \mathbb{E}_{x, M} \left[\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \left(1 - \cos \left(h_{\text{D}}^{(\ell)}(\tilde{x})_i, \text{stopgrad}(h_{\text{AR}}^{(\ell)}(x)_i) \right) \right) \right], \quad (2)$$

其中， $\mathcal{I}$ 是对齐的位置集合（默认：所有位置），教师模型以评估模式运行，并使用停止梯度。Intuitively, the teacher provides a stable representational coordinate system induced by next-token pretraining, and the student learns a denoising mechanism that operates within this coordinate system. 余弦距离、对齐层以及对齐强度的选择在第 4.3 节中进行了消融分析，而用于对齐的确切隐藏状态元组和掩码位置在第 B.4 节中给出。

3.4 训练目标

完整目标是一个加权和：

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{diff}}(\theta) + \lambda \mathcal{L}_{\text{align}}(\theta), \quad (3)$$

其中标量 λ （默认设为 10，）用于控制锚点的强度。我们在保持 θ_{AR} 固定的同时优化 θ 。总体而言，这一过程尽可能少地改变原有内容：架构是共享的，预训练的 AR 表征得以保留，而扩散训练被简化为在已形成的特征空间内学习一种任意顺序的去噪机制。除了标准的掩码扩散模型损失之外，我们还将先前工作中的 PAMPL [Peng et al., 2026] 损失作为默认 DLM 训练方案的一部分，并将其权重设为 1。第 4.2 至 4.3 节测试方程 (3) 中的对齐项是否能提升转换质量，以及它对 λ 的敏感程度。

4 实验

4.1 实验设置

AR 到 DLM 转换设置。我们研究使用 Qwen3 检查点 [Yang, 将自回归 (AR) 因果语言模型高效适配为掩码扩散语言模型 (DLM) 的方法。

et al., 2025] 在三个规模 (0.6B、1.7B 和 4B 参数) 上。对于每个规模, 我们将原始因果模型视为冻结的教师, 并从同一检查点初始化 DLM 学生, 只将注意力掩码从因果改为双向。这一设置实现了第 3.1 节中的同架构构造。

训练数据。我们在 Nemotron-SFT-Code 数据集 [NVIDIA et al., 2025] 上进行训练 (约 50B 个 token 和 70M 个序列)。该版本是一个大规模合成生成并经过筛选的 SFT 风格语料库, 涵盖 STEM、学术、推理和多语言指令数据, 并在 Nemotron-SFT-Code 子集中包含以代码为重点的指令数据。由此得到的训练流包含约 70M 个序列和 $\sim 50B$ 个 token。为研究数据效率, 我们还考虑了一个 *tiny* 子集, 它是通过均匀下采样构造到 $\sim 0.8B$ 个 token。对于固定计算量的比较, 我们采用有放回采样, 以使优化步数一致。在完整和小规模两种设置下, 训练样本均采用有放回采样, 因此优化预算由步数 (从而由处理的 token 总数) 而不是 epoch 来控制。第 4.2 节中的小数据比较使用了这种步数匹配的构造。

表示对齐。除了去噪损失之外, 我们还采用逐层表示对齐, 将学生模型锚定到冻结的 AR 教师模型。教师接收 *clean* 序列, 采用 x (因果注意力), 而学生接收被破坏的 $\tilde{x}$ (双向注意力)。我们使用余弦距离损失, 在每个 token 位置对每个 transformer 块的输出进行对齐, 其中教师特征停止梯度, 并且教师以评估模式运行。我们使用 $\lambda = 10$ 作为默认对齐权重, 该值来源于表 2 中的消融实验。此外, 我们在 *all* 运行中启用 PAPL 损失 [Peng et al., 2026], 权重为 1。除非另有说明, 我们将 PAPL 视为默认 DLM 训练方案的一部分, 并将其包含在 *all* 方法 (基线和对齐) 中, 从而使比较能够隔离表示对齐的影响。第 4.3 节会在该对齐项中变化度量、层集合和 λ 。

优化、批处理和评估。我们使用 AdamW 进行优化, 学习率为 3×10^{-4} , 采用余弦衰减、0.001 的 warmup 比例、0.01 的权重衰减、梯度裁剪 (最大范数 1.0) 以及混合精度训练。最大序列长度为 4096, 全局批大小为每个优化步骤 96 个序列。我们在 HumanEval [Chen et al., 2021]、MBPP [Austin et al., 2021b] 及其 EvalPlus 变体 [Liu et al., 2023] 上评估代码生成。HumanEval 使用标准的 docstring 提示, 所有评估均为 zero-shot。对于解码, 我们使用 P2-self sampling [Peng et al., 2025], 设置 128 个采样步数、`max_new_tokens = 128`、温度 0.8, 以及 `top-p = 0.95`。完整的数据预处理、优化、解码和评估配置见 B.2、B.6 和 B.7 节。

4.2 结果

实验围绕第 3 节引出的四个问题展开。首先, 公式 (2) 中的对齐项是否在匹配的训练预算下改进了 AR $\rightarrow$ DLM 适配? 其次, 这些增益是否会随着模型规模增大而扩展? 第三, 表征保持是否减少了更新所有参数的必要性? 第四, 当适配数据大幅减少时, 转换是否仍然有效? 下面的段落将分别回答这些问题。

REPR-ALIGN 提高了适配效率和质量。图 3 在固定的 200k 步预算下评估了 HumanEval 上的自回归到扩散转换。从同一个预训练的 Qwen3 检查点出发, 基线执行掩码扩散训练 (采用 MDLM 风格的掩码、shift 约定和 PAPL), 而我们的方法则额外通过逐层余弦对齐将学生模型锚定到冻结的 AR 教师模型。REPR-ALIGN 在整个训练过程中持续提升 `pass@10`, 表明在适配过程中具有显著更好的样本效率。在 200k 步截断时, 对齐后的模型取得了比基线更高的 `pass@10` (在 0.6B 上提升 6.1 分, 在 1.7B 上提升 9.4 分), 这表明即使学生模型采用双向去噪目标进行训练, 锚定预训练表示仍然是有益的。这验证了第 3.1 节中匹配转换设置下式 (2) 所编码的对齐假设。

对齐收益会随着模型规模增大而增长。图 3 总结了在不同模型规模下相同的转换过程。对于每个规模, 我们在相同的评估条件下比较了基线版本和对齐版本在训练 20 万步后的最后一个检查点。我们观察到, 对齐带来的收益会随着




图3：REPR-ALIGN 同时提升了适应速度和最终质量。左图：在 AR→DLM 转换过程中，Qwen3-0.6B 的 HumanEval pass@10 随训练步数变化；将表示对齐加入冻结的 AR 教师中，可在整个训练过程中提高样本效率。右图：0.6B 和 1.7B 模型的 pass@10 结果；表示对齐在 1.7B 上带来的提升大于在 0.6B 上的提升。

模型容量：对齐带来的绝对提升在 1.7B 模型上比在 0.6B 模型上更大。这一缩放趋势支持这样一种观点：AR 预训练学到了一种强大的表征几何结构，而随着模型容量增大，保留这种结构的价值也越来越高；与此同时，剩余的适配主要涉及由注意力掩码和去噪动力学所引入的生成机制。这直接检验了当 AR 教师的表征能力增强时，式 (3) 中的保留项是否变得更

有用。oDLM 与公开的扩散语言模型具有竞争力。图 1b 给出了促使本文工作的高层比较：在转换之后，oDLM 在代码生成 pass@10 上达到了公开扩散语言模型的前沿水平，同时使用的是预训练的 AR 表示，而不是从头重新训练一个扩散 LM。表 1 汇报了在 HumanEval、Human Eval+、MBPP 和 MBPP+ 上相对于近期公开 DLM 系统的完整基准分解，其中像 DiffuCoder 和 Dream-Coder 这样的面向代码的扩散 LM 为这一评测设置提供了高度相关的背景 [Nie et al., 2025b, Ye et al., 2025, Gong et al., 2025b, Xie et al., 2025]。表现最强的 oDLM 检查点在 pass @10 上尤其具有竞争力，而该指标最直接地与迭代扩散采样质量相关。这一比较评估的是公式 (3) 中的完整目标，而不是仅孤立地评估对齐项。

表1：在 HumanEval、HumanEval+、MBPP 和 MBPP+ 基准上的代码生成结果，并与近期公开的扩散语言模型 [Nie et al., 2025b, Ye et al., 2025] 进行比较。

Model	HumanEval		HumanEval+		MBPP		MBPP+	
	Pass@1	Pass@10	Pass@1	Pass@10	Pass@1	Pass@10	Pass@1	Pass@10
LLaDA (8B)	35.4	50.0	30.5	43.3	38.8	53.4	52.6	69.1
Dream (7B)	56.7	59.2	50.0	53.7	55.4	56.2	71.5	72.5
Mask DFM (1.3B)	9.1	17.6	7.9	13.4	6.2	25.0	–	–
Edit Flow (1.3B)	12.8	24.3	10.4	20.7	10.0	36.4	–	–
oDLM (0.6B)	17.87	35.98	16.40	31.10	15.70	37.00	22.99	49.47
oDLM (4B)	30.49	61.59	26.95	56.10	14.42	37.00	20.24	47.35

冻结大型参数块可以在略微提升质量的同时提高吞吐量。如果 AR 预训练已经提供了强表征，而表征对齐在转换过程中保留了教师的内部特征空间，那么 AR→DLM 适配就不应需要更新整个网络。我们通过对齐后的学生模型中冻结大型参数块，同时保持其余训练协议不变来验证这一点。图 4 显示，在 1.7B 规模下，性能与效率之间存在良好的权衡：冻结 token embedding，进一步更激进地冻结 embedding 和 MLP 块，都会显著提升训练吞吐量（最高可达 ~2×），同时保持甚至略微提高 HumanEval pass@10。这支持这样一种观点：一旦表征被锚定，剩余的学习信号就主要集中在双向注意力下对去噪机制的适配上，而冻结则提供了一个实用的调节手段，可以在不牺牲质量的前提下降低转换成本。该结果检验了第 3.3 节中关于机制适配的解释；冻结协议见附录 B.9。




图 4：冻结可提升训练效率，并带来轻微的性能提升（1.7B）。所有运行都使用表示对齐，并共享相同的训练流程和预算；我们仅改变冻结哪些参数块。冻结嵌入和 MLP 模块可将吞吐量提高至 $\sim 2\times$ ，同时略微提升 HumanEval pass@10。




图5：对齐并不依赖大量数据：一个很小的子集也能提升转换效果。*tiny* 运行在 0.8B token 的随机子样本上训练，而不是在完整的 50B token 流上训练。通过表示对齐，这个小子集在 pass@1（左）和 pass@10（右）上始终更高，支持这样一种观点：AR→DLM 转换主要是机制适配，而不需要海量训练数据。

对齐尤其高效利用数据：少量数据就能提升转换效果。为测试 AR 到 DLM 的转换是否本质上数据需求很高，我们将训练语料从完整的 500 亿 token Nemotron-SFT-Code 流缩减为一个 *tiny* 8 亿 token 的随机子样本，同时保持优化预算不变（相同的批大小、序列长度和步数；少量数据采用有放回采样）。图 5 展示了一个清晰且有些出人意料的结果：在表示对齐的情况下，在这个小子集上训练得到的 *higher* HumanEval pass@10 高于在相同步数下使用完整数据流训练的结果。这表明，一旦预训练的 AR 表示得以保留，剩余的学习问题主要是 *mechanism adaptation*（适配双向注意力和去噪动力学），而在固定步数预算下，只需极少的数据就能完成。这验证了公式 (2) 中将学生模型锚定到教师表示所带来的低数据需求含义。

实用结论。跨越不同规模和数据条件，我们的实验支持一种简单的高效训练扩散语言模型的方案。给定一个预训练的自回归（AR）Transformer，我们可以通过切换到双向注意力、使用带有移位约定的 MDLM 风格去噪目标进行训练，以及通过逐层余弦损失将中间表示锚定到冻结的 AR 教师模型，将其转换为一个具有竞争力的掩码扩散模型。当算力受限时，冻结词元嵌入，甚至冻结 MLP 模块，也会在几乎不损失或完全不损失质量的情况下进一步提升效率。当数据受限时，对齐机制即使在极小的数据子集上也能实现有效适配，这表明，大规模扩散预训练的成本并非固有，而主要反映了对 AR 预训练已经提供的表示进行重新学习。

表 2：HumanEval 上表示对齐的消融实验。

Metric			Weight			Layers		
Variant	pass@1	pass@10	λ	pass@1	pass@10	Variant	pass@1	pass@10
L2	12.00	25.00	1	7.50	22.60	Lower	11.28	25.00
Cosine	18.00	31.00	5	9.90	26.80	Middle	15.73	31.10
			10	18.00	31.00	Upper	8.96	31.71
			20	11.30	29.30	All	18.00	31.00

4.3 消融研究

我们对公式 (2) 和 (3) 中的主要设计选择进行了消融：用于匹配隐藏状态的距离度量、对齐项的强度 λ ，以及包含在对齐损失中的层集合。除非另有说明，所有消融实验都使用相同的 AR→DLM 转换协议：学生模型从 AR 检查点初始化，采用双向掩码去噪进行训练，在 HumanEval 上评估，并使用相同的采样配置进行解码。该设置用于隔离性能提升是否源于保留预训练表示的几何结构，而非架构或解码方式的变化。表 2 总结了主要的消融结果。余弦对齐是最佳的默认度量； $\lambda = 10$ 提供了最强的整体锚定；而全层对齐在保持具有竞争力的 pass@10 的同时，实现了最佳的 pass@1。

余弦对齐比通过 L2 匹配隐藏状态更好。我们首先比较表示损失的两种自然选择：隐藏状态上的 L2 损失和余弦距离损失。这直接检验了式 (2) 中的余弦距离选择。余弦对齐将 HumanEval 的 pass@1 从 12.0 提升到 18.0，并将 pass@10 从 25.0 提升到 31.0，表明 AR teacher 中有用的信号主要是几何性的，而非度量性的。由于 transformer 的隐藏状态范数会随层、token 和训练状态而变化，L2 目标可能会被尺度所主导；而余弦对齐则保留了表示方向。因此，我们将余弦对齐作为默认的损失。

对齐权重控制着锚定与适应之间的权衡。接下来，我们在公式 (3) 中改变对齐权重 λ ，它控制着锚定到 AR 教师与适应去噪目标之间的权衡。扫描结果显示出明显的权衡：较弱的对齐会使 AR 教师的利用不足，而过强的锚定会限制扩散学生。性能从 $\lambda = 1$ 提升到 $\lambda = 10$ ，达到 18.0 的 pass@1 和 31.0 的 pass@10，但在 $\lambda = 20$ 时下降。这支持将表示对齐视为一种辅助约束，而不是对教师的精确模仿。因此，我们默认将 $\lambda =$ 设为 10。

对齐的位置很重要。最后，我们将隐藏状态划分为下、中、上三部分，以测试 AR 教师在哪些位置最有用。中层和上层锚点提升了 pass@10，但只有全层对齐才能在保持有竞争力的 pass@10 的同时带来最强的 pass@1。因此，可迁移信号似乎分布在整个深度上。基于此，我们默认使用全层余弦对齐。

5 结论

在这项工作中，我们挑战了自回归语言模型与扩散语言模型之间的主流二分法。我们的实证研究证实，在标准自回归预训练过程中获得的丰富语义表征并不局限于序列解码，而是可广泛适用于非自回归生成。通过引入 REPR-ALIGN，我们展示了可以直接继承这种语义拓扑。我们以远低于标准预训练成本的一小部分，实现了最先进的性能。

我们的发现对离散生成具有更广泛的意义。诸如均匀、潜变量和单纯形扩散模型等替代框架，历来都难以实现规模化，往往是由于优化困难。通过将新的生成机制锚定于稳健的 AR 先验，REPR-ALIGN 提供了一种适应预训练表示的方法，而不是从头开始训练每一种范式。我们希望这能推动一种转变，即将机制对齐作为一种实用方式，以释放新的生成形式。

致谢与资金披露

我们感谢 Jarrid Rector-brooks 提供的有益讨论和帮助。F.Z.P. 和 A.R.Z. 部分得到 NIH R01HL169347 的资助。

参考文献

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat 等。Gpt-4 技术报告。arXiv, 2023。2 Jacob Austin, Daniel D. Johnson, Jonathan Ho, Daniel Tarlow 和 Rianne van den Berg。离散状态空间中的结构化去噪扩散模型。arXiv, 2021a。2、3、14 Jacob Austin, Augustus Odena, Maxwell Nye, Maarten Bosma, Henryk Michalewski, David Dohan, Ellen Jiang, Carrie Cai, Michael Terry, Quoc Le 和 Charles Sutton。使用大语言模型进行程序合成, 2021b。URL <https://arxiv.org/abs/2108.07732>。6、19 Andrew Campbell, Joe Benton, Valentin De Bortoli, Tom Rainforth, George Deligiannidis 和 Arnaud Doucet。离散去噪模型的连续时间框架, 2022。14 Huiwen Chang, Han Zhang, Lu Jiang, Ce Liu 和 William T. Freeman。Maskgit: 掩码生成式图像 Transformer。在 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* 中, 第 11315 – 11325 页, 2022。2、16 Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, Alex Ray, Raul Puri, Gretchen Krueger, Michael Petrov, Heidy Khlaaf, Girish Sastry, Pamela Mishkin, Brooke Chan, Scott Gray, Nick Ryder, Mikhail Pavlov, Alethea Power, Lukasz Kaiser, Mohammad Bavarian, Clemens Winter, Philippe Tillet, Felipe Petroski Such, Dave Cummings, Matthias Plappert, Fotios Chantzis, Elizabeth Barnes, Ariel Herbert-Voss, William Hebgen Guss, Alex Nichol, Alex Paino, Nikolas Tezak, Jie Tang, Igor Babuschkin, Suchir Balaji, Shantanu Jain, William Saunders, Christopher Hesse, Andrew N. Carr, Jan Leike, Josh Achiam, Vedant Misra, Evan Morikawa, Alec Radford, Matthew Knight, Miles Brundage, Mira Murati, Katie Mayer, Peter Welinder, Bob McGrew, Dario Amodei, Sam McCandlish, Ilya Sutskever 和 Wojciech Zaremba。对在代码上训练的大语言模型进行评估, 2021。URL <https://arxiv.org/abs/2107.03374>。6、19 Yonggan Fu, Lexington Whalen, Zhifan Ye, Xin Dong, Shizhe Diao, Jingyu Liu, Chengyue Wu, Hao Zhang, Enze Xie, Song Han, Maksim Khadkevich, Jan Kautz, Yingyan Celine Lin 和 Pavlo Molchanov。Efficient-dlm: 从自回归到扩散语言模型, 以及在速度上的进一步发展, 2025。URL <https://arxiv.org/abs/2512.14067>。2、3、15 Marjan Ghazvininejad, Omer Levy, Yinhan Liu 和 Luke Zettlemoyer。Mask-predict: 条件掩码语言模型的并行解码。在 *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing* 中, 第 6112 – 6121 页。计算语言学协会, 2019。doi: 10.18653/v1/D19-1633。URL <https://aclanthology.org/D19-1633/>。2、16 Shansan Gong, Shivam Agarwal, Yizhe Zhang, Jiacheng Ye, Lin Zheng, Mukai Li, Chenxin An, Peilin Zhao, Wei Bi, Jiawei Han, Hao Peng 和 Lingpeng Kong。通过从自回归模型迁移来扩展扩散语言模型。在 *International Conference on Learning Representations* 中, 2025a。2、3、15 Shansan Gong, Ruixiang Zhang, Huangjie Zheng, Jiatao Gu, Navdeep Jaitly, Lingpeng Kong 和 Yizhe Zhang。Diffucoder: 理解并改进用于代码生成的掩码扩散模型, 2025b。URL <https://arxiv.org/abs/2506.20639>。7、15 Ishaan Gulrajani 和 Tatsunori Hashimoto。基于似然的扩散语言模型。Neural Information Processing Systems, 2023。2、3、14 Jonathan Ho, Ajay Jain 和 Pieter Abbeel。去噪扩散概率模型。Advances in neural information processing systems, 33:6840 – 6851, 2020。2

Dengyang Jiang, Mengmeng Wang, Liuzhuozheng Li, Lei Zhang, Haoyu Wang, Wei Wei, Guang Dai, Yanning Zhang 和 Jingdong Wang。无需其他表示组件：扩散 Transformer 本身就能提供表示引导。arXiv preprint arXiv:2505.02831, 2025。2, 4, 16 Xiang Lisa Li, John Thickstun, Ishaan Gulrajani, Percy Liang 和 Tatsunori B. Hashimoto。Diffusion- lm 提升可控文本生成。在 *Advances in Neural Information Processing Systems*, 2022。2, 3, 14 Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang 和 Lingming Zhang。你的代码真的是由 chatgpt 生成的吗？用于代码生成的大语言模型的严格评估。在 *Advances in Neural Information Processing Systems*, 2023。URL <https://openreview.net/forum?id=1qv610Cu7>。6, 19 Aaron Lou, Chenlin Meng 和 Stefano Ermon。通过估计数据分布比率进行离散扩散建模。在 *International Conference on Machine Learning*, 2023。14 Shen Nie, Fengqi Zhu, Chao Du, Tianyu Pang, Qian Liu, Guangtao Zeng, Min Lin 和 Chongxuan Li。面向文本的掩码扩散模型规模扩展。 *International Conference on Learning Representations*, 2025a。3, 14 Shen Nie, Fengqi Zhu, Zebin You, Xiaolu Zhang, Jingyang Ou, Jun Hu, Jun Zhou, Yankai Lin, Ji-Rong Wen 和 Chongxuan Li。大型语言扩散模型, 2025b。URL <https://arxiv.org/abs/2502.09992>。2, 3, 7, 14 NVIDIA, :, Aarti Basant, Abhijit Khairnar, Abhijit Paithankar, Abhinav Khattar, Adithya Renduchintala, Aditya Malte, Akhiad Bercovich, Akshay Hazare, Alejandra Rico, Aleksander Ficek, Alex Kondratenko, Alex Shaposhnikov, Alexander Bukharin, Ali Taghibakhshi, Amelia Barton, Ameya Sunil Mahabaleshwarkar, Amy Shen, Andrew Tao, Ann Guan, Anna Shors, Anubhav Mandarwal, Arham Mehta, Arun Venkatesan, Ashton Sharabiani, Ashwath Aithal, Ashwin Poojary, Ayush Dattagupta, Balaram Buddhharaju, Banghua Zhu, Barnaby Simkin, Bilal Kartal, Bitan Darvish Rouhani, Bobby Chen, Boris Ginsburg, Brandon Norick, Brian Yu, Bryan Catanzaro, Charles Wang, Charlie Truong, Chetan Mungekar, Chintan Patel, Chris Alexiuk, Christian Munley, Christopher Parisien, Dan Su, Daniel Afrimi, Daniel Korzekwa, Daniel Rohrer, Daria Gitman, David Mosalanezhad, Deepak Narayanan, Dima Rekesh, Dina Yared, Dmytro Pykhtar, Dong Ahn, Duncan Riach, Eileen Long, Elliott Ning, Eric Chung, Erick Galinkin, Evelina Bakhturina, Gargi Prasad, Gerald Shen, Haifeng Qian, Haim Elisha, Harsh Sharma, Hayley Ross, Helen Ngo, Herman Sahota, Hexin Wang, Hong Chang Shin, Hua Huang, Iain Cunningham, Igor Gitman, Ivan Moshkov, Jaehun Jung, Jan Kautz, Jane Polak Scowcroft, Jared Casper, Jian Zhang, Jiaqi Zeng, Jimmy Zhang, Jinze Xue, Jocelyn Huang, Joey Conway, John Kamalu, Jonathan Cohen, Joseph Jennings, Julien Veron Vialard, Junkeun Yi, Jupinder Parmar, Kari Briski, Katherine Cheung, Katherine Luna, Keith Wyss, Keshav Santhanam, Kezhi Kong, Krzysztof Pawelec, Kumar Anik, Kunlun Li, Kushan Ahmadian, Lawrence McAffee, Laya Sleiman, Leon Derczynski, Luis Vega, Maer Rodrigues de Melo, Makesh Narsimhan Sreedhar, Marcin Chochowski, Mark Cai, Markus Kliegl, Marta Stepniewska-Dziubinska, Matvei Novikov, Mehrzad Samadi, Meredith Price, Meriem Boubdir, Michael Boone, Michael Evans, Michal Bien, Michal Zawalski, Miguel Martinez, Mike Chrzanowski, Mohammad Shoeybi, Mostafa Patwary, Namit Dhameja, Nave Assaf, Negar Habibi, Nidhi Bhatia, Nikki Pope, Nima Tajbakhsh, Nirmal Kumar Juluru, Oleg Rybakov, Oleksii Hrinchuk, Oleksii Kuchaiev, Oluwatobi Olabiyi, Pablo Ribalta, Padmavathy Subramanian, Parth Chadha, Pavlo Molchanov, Peter Dykas, Peter Jin, Piotr Bialecki, Piotr Januszewski, Pradeep Thalasta, Prashant Gaikwad, Prasoon Varshney, Pritam Gundecha, Przemek Tredak, Rabeeh Karimi Mahabadi, Rajen Patel, Ran El-Yaniv, Ranjit Rajan, Ria Cheruvu, Rima Shahbazy, Ritika Borkar, Ritu Gala, Roger Waleffe, Ruoxi Zhang, Russell J. Hewett, Ryan Prenger, Sahil Jain, Samuel Krizan, Sanjeev Satheesh, Saori Kaji, Sarah Yurick, Saurav Muralidharan, Sean Narenthiran, Seonmyeong Bak, Sepehr Sameni, Seungju Han, Shanmugam Ramasamy, Shaona Ghosh, Sharath Turuvekere Sreenivas, Shelby Thomas, Shizhe Diao, Shreya Gopal, Shrimai Prabhumoye, Shubham Toshniwal, Shuoyang Ding, Siddharth Singh, Siddhartha Jain, Somshubra Majumdar, Soumye Singhal, Stefania Alborghetti, Syeda Nahida Akter, Terry Kong, Tim Moon, Tomasz Hliwiak, Tomer Asida, Tony Wang, Tugrul Konuk, Twinkle Vashishth, Tyler Poon, Udi Karpas, Vahid Noroozi, Venkat Srinivasan, Vijay Korthikanti, Vikram Fugro, Vineeth Kalluru, Vitaly Kurin, Vitaly Lavrukhin, Wasi Uddin Ahmad, Wei Du, Wonmin Byeon, Ximing Lu, Xin Dong, Yashaswi Karnati, Yejin Choi, Yian Zhang, Ying

Lin, Yonggan Fu, Yoshi Suhara, Zhen Dong, Zhiyu Li, Zhongbo Zhu 和 Zijia Chen。Nvidia Neomotron Nano 2：一种准确高效的混合 Mamba-Transformer 推理模型，2025。URL <https://arxiv.org/abs/2508.14444>。6 Fred Zhangzhi Peng、Zachary Bezemek、Sawan Patel、Jarrid Rector-Brooks、Sherwood Yao、Avishek Joey Bose、Alexander Tong 和 Pranam Chatterjee。用于掩码扩散模型采样的路径规划，2025。URL <https://arxiv.org/abs/2502.03540>。6, 16 Fred Zhangzhi Peng、Zachary Bezemek、Jarrid Rector-Brooks、Shuibai Zhang、Michael M. Bronstein、Anru Zhang、Joey Bose 和 Alexander Tong。扩散语言模型训练中的规划感知路径学习。发表于 *The Fourteenth International Conference on Learning Representations*, 2026。URL <https://openreview.net/forum?id=1A1I5FuIf7>。5, 6, 16 Alec Radford、Jeff Wu、Rewon Child、David Luan、Dario Amodei 和 Ilya Sutskever。语言模型是无监督多任务学习者。preprint, 2019。2 Subham Sekhar Sahoo、Marianne Arriola、Aaron Gokaslan、Edgar Mariano Marroquin、Alexander M Rush、Yair Schiff、Justin T Chiu 和 Volodymyr Kuleshov。简单而有效的掩码扩散语言模型。发表于 *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024。2, 3, 14 Andy Shih、Dorsa Sadigh 和 Stefano Ermon。正确地对任意顺序自回归模型进行训练和推理。 *Neural Information Processing Systems*, 2022。16 Jaskirat Singh、Xingjian Leng、Zongze Wu、Liang Zheng、Richard Zhang、Eli Shechtman 和 Saining Xie。表示对齐中什么更重要：全局信息还是空间结构？arXiv preprint arXiv:2512.10794, 2025。2, 4, 16 Jascha Sohl-Dickstein、Eric Weiss、Niru Maheswaranathan 和 Surya Ganguli。利用非平衡热力学进行深度无监督学习。载于 Francis Bach 和 David Blei 编辑, *Proceedings of the 32nd International Conference on Machine Learning*, 第 37 卷, 属于 *Proceedings of Machine Learning Research*, 第 2256 – 2265 页, 法国里尔, 2015 年 7 月 07 – 09 日。PMLR。URL <https://proceedings.mlr.press/v37/sohl-dickstein15.html>。2 Hugo Touvron、Louis Martin、Kevin R. Stone、Peter Albert、Amjad Almahairi、Yasmine Babaei、Nikolay Bashlykov、Soumya Batra、Prajwal Bhargava、Shruti Bhosale、Daniel M. Bikel、Lukas Blecher、Cristian Cantón Ferrer、Moya Chen、Guillem Cucurull、David Esioibu、Jude Fernandes、Jeremy Fu、Wenyin Fu、Brian Fuller、Cynthia Gao、Vedanuj Goswami、Naman Goyal、Anthony S. Hartshorn、Saghar Hosseini、Rui Hou、Hakan Inan、Marcin Kardas、Viktor Kerkez、Madian Khabsa、Isabel M. Kloumann、A. V. Korenev、Punit Singh Koura、Marie-Anne Lachaux、Thibaut Lavril、Jenya Lee、Diana Liskovich、Yinghai Lu、Yuning Mao、Xavier Martinet、Todor Mihaylov、Pushkar Mishra、Igor Molybog、Yixin Nie、Andrew Poulton、Jeremy Reizenstein、Rashi Rungta、Jacob Hilton、Reiichiro Nakano、Christopher Hesse、John Schulman、Rishi Rungta、Kalyan Saladi、Alan Schelten、Ruan Silva、Eric Michael Smith、R. Subramanian、Xia Tan、Binh Tang、Ross Taylor、Adina Williams、Jian Xiang Kuan、Puxin Xu、Zhengxu Yan、Iliyan Zarov、Yuchen Zhang、Angela Fan、Melissa Hall Melanie Kambadur、Sharan Narang、Aurélien Rodriguez、Robert Stojnic、Sergey Edunov 和 Thomas Scialom。Llama 2：开放基础模型和微调聊天模型。arXiv, 2023。2 Ge Wu、Shen Zhang、Ruijing Shi、Shanghua Gao、Zhenyuan Chen、Lei Wang、Zhaowei Chen、Hongcheng Gao、Yao Tang、Jian Yang、Ming-Ming Cheng 和 Xiang Li。用于生成的表示纠缠：训练扩散 Transformer 比你想象的容易得多。arXiv preprint arXiv:2507.01467, 2025。2, 4, 16 Zhihui Xie、Jiacheng Ye、Lin Zheng、Jiahui Gao、Jingwei Dong、Zirui Wu、Xueliang Zhao、Shansan Gong、Xin Jiang、Zhenguo Li 和 Lingpeng Kong。Dream-Coder 7B：一个用于代码的开放扩散语言模型, 2025。URL <https://arxiv.org/abs/2509.01142>。3, 7, 15 Shuchen Xue、Tianyu Xie、Tianyang Hu、Zijin Feng、Jiacheng Sun、Kenji Kawaguchi、Zhenguo Li 和 Zhi-Ming Ma。任意顺序 GPT 作为掩码扩散模型：解耦形式化与架构, 2025。URL <https://arxiv.org/abs/2506.19935>。3, 15

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, Chujie Zheng, Dayiheng Liu, Fan Zhou, Fei Huang, Feng Hu, Hao Ge, Haoran Wei, Huan Lin, Jialong Tang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jing Zhou, Jingren Zhou, Junyang Lin, Kai Dang, Keqin Bao, Kexin Yang, Le Yu, Lianghao Deng, Mei Li, Mingfeng Xue, Mingze Li, Pei Zhang, Peng Wang, Qin Zhu, Rui Men, Ruize Gao, Shixuan Liu, Shuang Luo, Tianhao Li, Tianyi Tang, Wenbiao Yin, Xingzhang Ren, Xinyu Wang, Xinyu Zhang, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yinger Zhang, Yu Wan, Yaqiong Liu, Zekun Wang, Zeyu Cui, Zhenru Zhang, Zhipeng Zhou, and Zihan Qiu. Qwen3 技术报告, 2025. URL <https://arxiv.org/abs/2505.09388>. 5 Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Carbonell, Ruslan Salakhutdinov, and Quoc V. Le. XLNet: 用于语言理解的广义自回归预训练。载于 *Advances in Neural Information Processing Systems*, 2019. 2, 15 Jiacheng Ye, Zhihui Xie, Lin Zheng, Jiahui Gao, Zirui Wu, Xin Jiang, Zhenguo Li, and Lingpeng Kong. Dream 7b: 扩散大语言模型, 2025. URL <https://arxiv.org/abs/2508.15487>. 2, 3, 7, 14, 15 Sihyun Yu, Sangkyung Kwak, Huiwon Jang, Jongheon Jeong, Jonathan Huang, Jinwoo Shin, and Saining Xie. 用于生成的表示对齐: 训练扩散 Transformer 比你想象的更容易。载于 *International Conference on Learning Representations*, 2025. 2, 4, 15, 16

附录内容

A 扩展相关工作 14

A.1 扩散语言模型	14
A.2 自回归到扩散语言模型的转换	15
A.3 任意顺序生成、迭代解码与路径规划	15
A.4 表示对齐与特征保留	16

B 实验细节 17

B.1 模型转换	17
B.2 数据与预处理	17
B.3 掩码扩散目标	17
B.4 表征对齐	18
B.5 路径规划损失	19
B.6 优化	19
B.7 解码与评估	19
B.8 消融实验协议	20
B.9 冻结协议	20

C 限制 21

D 更广泛影响 21

A 扩展相关工作

本附录提供了与最相近工作线索的更详细比较。其目的并不是穷尽性地综述所有扩散或语言生成方法，而是澄清我们方法的具体定位：我们研究通过 *representation preservation* 进行 $A \rightarrow DLM$ 转换。现有的转换方法表明，预训练的自回归检查点是扩散语言模型有用的初始化，但它们主要是在调整目标函数、注意力模式、掩码约定或采样过程。相比之下，我们的方法通过将 DLM 学生锚定到一个冻结的、同架构的 AR 教师，显式保留了预训练 AR 模型的隐藏状态几何结构。本附录为第 2 节中的定位主张以及第 3.3 节中形式化的方法学区分提供支持。

A.1 扩散语言模型

扩散语言模型已经通过几种不同的形式化方式发展起来。早期方法通过在词嵌入或潜在表示上施加连续扩散，将扩散引入语言生成中 [Li et al., 2022]。与此同时，离散扩散模型直接在分类状态空间上定义腐化和去噪过程，包括结构化离散转移核、连续时间马尔可夫形式、比率估计目标以及基于似然的语言建模目标 [Austin et al., 2021a, Campbell et al., 2022, Lou et al., 2023, Gulrajani and Hashimoto, 2023]。更近期的掩码扩散语言模型通过使用吸收式掩码腐化和掩码 token 去噪目标，简化了离散扩散过程，从而在似然和生成性能上表现强劲，其训练目标与掩码语言建模高度相关 [Sahoo et al., 2024, Nie et al., 2025a]。LLaDA 和 Dream 等大规模系统进一步表明，扩散语言模型能够在十亿参数规模上支持指令遵循、推理以及通用语言生成 [Nie et al., 2025b, Ye et al., 2025]。

表3：与密切相关的 AR 到 DLM 转换及表示对齐方法的比较。现有的 AR 到 DLM 方法会复用预训练的 AR 参数，但在去噪训练过程中并不会显式保留 AR 模型的隐藏状态几何结构。REPA 风格的方法使用表示对齐，但通常是将扩散模型与外部编码器对齐，而不是与正在被转换的同一个 AR 模型对齐。

Method	Starts from AR LM	DLM target	Hidden alignment	Same-architecture AR teacher
Gong et al. [Gong et al., 2025a]	Yes	Yes	No	No
Dream [Ye et al., 2025]	Yes	Yes	No	No
Dream-Coder [Xie et al., 2025]	Yes	Yes	No	No
Efficient-DLM [Fu et al., 2025]	Yes	Yes	No	No
Any-Order GPT [Xue et al., 2025]	Yes	Yes	No	No
REPA [Yu et al., 2025]	No	Yes	Yes	No
Ours	Yes	Yes	Yes	Yes

我们的工作与扩散参数化的选择是正交的。我们将掩码去噪目标用作目标转换目标，但我们并未提出新的离散扩散过程、转移核或似然估计器。相反，我们研究如何将一个预训练的 AR 模型转换为 DLM，而无需从头重新学习其内部语言表示。这将优化问题从完整的扩散预训练转变为保留表示的机制适配：DLM 必须学会在双向注意力和任意顺序生成下进行去噪，同时仍锚定于 AR 预训练已经形成的语义坐标系。主方法中使用的掩码去噪目标见第 3.2 节。

A.2 自回归到扩散语言模型转换

最接近的一类工作研究如何将预训练自回归语言模型适配为扩散语言模型。Gong 等人提出了最早的一套系统性 AR→DLM 适配方案之一，表明可以通过持续的扩散训练，将 GPT 和 LLaMA 风格的检查点转换为 DiffuGPT 和 DiffuLLaMA [Gong et al., 2025a]。这一转换中的一个关键要素，是协调 AR 模型的下一个 token 索引约定与掩码扩散的逐位置去噪约定，例如在训练和采样过程中通过移位操作来实现。后续的大规模 DLM 进一步利用了 AR 初始化。Dream 将基于 AR 的初始化与面向扩散的训练策略相结合，用于大规模扩散语言建模 [Ye et al., 2025]；而 Dream-Coder 则将预训练的 AR 检查点适配为用于代码生成的掩码扩散模型 [Xie et al., 2025]。Efficient-DLM 通过注意力和目标函数设计来研究这一转换问题，强调保留 AR 检查点的有利性质对于质量和推理效率都很重要 [Fu et al., 2025]。与此相关，Any-Order GPT 在仅解码器框架中将掩码扩散与任意顺序自回归生成联系起来，进一步强调 AR 和 DLM 之间的区别在某种程度上是生成机制的区别，而非模型家族的区别 [Xue et al., 2025]。像 DiffuCoder 这样的面向代码的扩散模型则提供了额外证据，表明在基于执行的代码生成场景中，掩码扩散可以具有竞争力 [Gong et al., 2025b]】。

这些工作表明，AR 检查点是 DLM 训练的有价值起点。然而，现有的转换方法主要是复用 AR 参数，然后通过目标级、注意力级、掩码级或采样级的改变来调整模型。它们并未显式约束转换后的 DLM 在训练全过程中保持 AR 模型的内部表示几何结构。我们的方法加入了这一缺失的约束。我们保留一个冻结的 AR 教师模型，从同一个检查点初始化 DLM 学生模型，将学生模型从因果注意力切换为双向注意力，并在去噪训练过程中将学生的隐藏状态与教师的逐层表示对齐。因此，我们的方法并不只是从 AR 模型初始化；它将 AR 模型作为持续的表示锚点。本文中相应的转换流程定义于第 3.1 节，并在第 4.2 节的匹配条件下进行了评估。

A.3 任意顺序生成、迭代替码和路径规划

我们的工作也与先前关于生成顺序的研究相关。自回归语言模型通常使用固定的从左到右分解进行训练，但这种分解只是联合分布的一种可能排序。XLNet 引入了排列语言建模，表明通过对多种分解顺序进行优化，自回归预训练可以融合双向上下文 [Yang et al., 2019]。更一般地，任意顺序的自回归模型研究

训练和推理，其中生成顺序允许变化，而不是事先固定 [Shih et al., 2022]。这些工作支持这样的观点：生成顺序是一种建模机制，而不是数据分布的内在属性。

迭代式掩码解码为掩码扩散生成提供了另一种前身。Mask-Predict 通过反复预测被掩码的位置并重新掩码低置信度词元来生成序列，提供了一种基于掩码语言模型的早期非自回归序列生成流程 [Ghazvininejad et al., 2019]。MaskGIT 随后在视觉词元模型中展示了基于置信度的迭代式掩码生成的有效性 [Chang et al., 2022]。现代掩码扩散语言模型可以看作这些迭代细化方法在概率上的后继：它们定义了一个显式的腐化过程，在部分掩码的序列上训练去噪器，并通过逐步消解各位置的不确定性来进行采样。

近期工作进一步表明，去噪路径和 token 顺序的选择会显著影响 DLM 的采样与训练。P2 研究了掩码扩散采样的路径规划，并表明，在不改变去噪模型的情况下，非均匀的重新掩码与更新调度可以提升生成质量 [Peng et al., 2025]。PAPL 将这一观点扩展到训练阶段，通过将感知规划器的路径学习纳入扩散语言模型优化 [Peng et al., 2026]。在本文中，我们将 PAPL 作为基线模型和表示对齐模型的默认 DLM 训练方案的一部分。因此，这些比较所隔离的是表示对齐的贡献，而不是路径规划改进的贡献。概念上，这一研究方向强化了我们的核心前提：如果生成顺序和去噪路径是可以在预训练后被改变的机制，那么关键问题就是，在机制发生变化的同时，底层语言表示是否能够被保留。PAPL 在我们的实验流程中的作用见附录 B.5 和第 4.1 节；由于 PAPL 在基线模型和对齐模型中是共享的，它并不构成比较轴。

A.4 表示对齐与特征保持

表示对齐最近已成为加速生成模型训练的一种有效方式。REPA 将扩散或基于流的 Transformer 的隐藏状态与强大的预训练视觉编码器的表征对齐，表明生成训练的瓶颈可能在于缓慢的表征学习，而不仅仅是去噪本身 [Yu et al., 2025]。后续工作研究目标表征的哪些组成部分最有用、全局信息还是空间结构更重要，以及扩散 Transformer 是否可以在没有外部编码器的情况下提供表征指导 [Singh et al., 2025, Wu et al., 2025, Jiang et al., 2025]。总体而言，这些方法表明，显式约束中间表征可以提高生成训练的效率和稳定性。

我们的设置在教师模型和对齐目的上都不同。以往的表示对齐方法通常将生成模型与外部编码器对齐，而且往往是在视觉领域中进行。教师和学生可能具有不同的架构、模态或训练目标，因此对齐相当于一种语义特征蒸馏。相比之下，我们的教师模型正是被转换的 AR 模型本身：它与转换前的 DLM 学生具有相同的分词器、Transformer 架构、隐藏维度以及预训练权重。学生唯一的不同在于，由双向注意力和掩码去噪所引入的生成机制。因此，对齐并不是用于从外部模型导入特征；它的作用是在学习新的去噪机制的同时，保留预训练 AR 模型的内部坐标系。

这种区别是我们解释的核心。如果 AR 预训练已经学到了有用的语义和句法表示，那么 AR $\rightarrow$ DLM 转换就不应该需要从头重新学习这些表示。剩下的问题是调整模型，使这些表示能够支持任意顺序的去噪，而不是从左到右的下一个 token 预测。逐层表示对齐直接实现了这一观点：它将 DLM 学生模型锚定到冻结的 AR 教师模型上，同时扩散损失训练学生在掩码双向生成下运行。由此得到的方法结合了 AR 初始化的实际优势，以及一个显式约束，用以在转换过程中保持 AR 模型的隐藏状态几何结构。该思想的同架构 AR 教师版本在第 3.3 节中形式化，并在第 4.3 节中进行了消融分析。

B 实验细节

本附录给出了第 4.1 节中总结并在第 4.2 节和第 4.3 节中使用的实验协议的实现细节。除非另有说明，所有实验都使用相同的模型初始化、数据预处理、掩码去噪目标、路径规划损失、优化配置和解码协议。消融实验仅在明确指出的因素上有所不同。

B.1 模型转换

我们通过在掩码扩散训练期间将注意力模式从因果改为双向，把一个预训练的自回归语言模型转换为掩码扩散语言模型。除此之外，Transformer 架构保持不变：该模型仍然是一个仅解码器的、Qwen 风格的 Transformer，采用旋转位置嵌入、RMSNorm、MLP 模块，以及绑定的输入嵌入/输出语言建模头。原始 AR 模型用作冻结的教师模型，而 DLM 学生模型则从同一个检查点初始化。这实现了第 3.1 节中的双模型构造。

在实现中，双向注意力模式仅在掩码扩散训练时启用。当前向传播接收到掩码比例时，模型设为 `is_causal=False`；否则，保持标准的因果模式。扩散生成使用全序列的非因果前向传播，不使用 KV 缓存。

清单 1：因果到双向转换。

```
# In Qwen*ForCausalLM.forward
if mask_ratio is not None:
    is_causal = False
else:
    is_causal = True

outputs = self.model(
    input_ids=input_ids,
    attention_mask=attention_mask,
    is_causal=is_causal,
    output_hidden_states=output_hidden_states,
```

在完成 AR 到 DLM 的适配后，我们采用单 token 左移约定，以协调下一 token 预测与按位置掩码去噪。在训练过程中，标签会左移，相应地，隐藏状态也会进行切片。在采样过程中，logits 会进行移位，使得扩散预测与继承下来的 AR 索引约定保持一致。基线模型和表示对齐模型都使用同样的移位约定。

B.2 数据与预处理

训练使用存储为本地 Parquet 文件的 Nemotron-SFT-Code 语料库。训练流以流式模式加载。每个样本从 `text` 字段中读取，附加一个 EOS 标记，并使用 `add_special_tokens=False` 进行分词。长度超过最大序列长度的样本会被切分为长度为 4096 的块，而较短的样本则保留并进行打包。启用打包时，多个样本会在重置位置 id 的情况下连接成打包后的行，从而保留序列边界。不应用额外的过滤。此预处理支持第 4.1 节中描述的数据场景，包括第 4.2 节中的小数据量对比。

实验中使用的主要资源如下授权或受以下条款约束：Qwen3 检查点依据 Apache 2.0 许可发布；Nemotron-SFT-Code 训练语料库受 NVIDIA 针对模型训练的数据访问条款约束；Human Eval 依据 OpenAI 最初的 MIT 许可发布；MBPP 通过 Google Research 数据集发布，依据 C C BY 4.0 许可发布；EvalPlus HumanEval+/MBPP+ 版本依据 Apache 2.0 许可发布。

B.3 掩码扩散目标

本节实现了公式 (1) 中的主要去噪损失。DLM 学生模型通过掩码去噪目标进行训练。对于每个原始序列，我们采样一个掩码比例

$$r \sim \text{Uniform}\left(\frac{1}{500}, 1 - \frac{1}{500}\right). \quad (4)$$

表 4：数据预处理配置。

Setting	Value
Dataset format	Local Parquet files
Number of files	78
Number of rows	76,447,340
Text field	text
Tokenization	append EOS, add_special_tokens=False
Maximum sequence length	4096
Long examples	split into 4096-token chunks
Short examples	kept and packed
Packing	concatenate examples with reset position ids
Shuffle seed	42
Shuffle buffer	10000
Filtering	none

在该比例条件下，每个 token 位置都以概率 r 独立地被遮蔽。因此，实现采用的是伯努利遮蔽，而不是精确选择 $\lfloor rn \rfloor$ 个被遮蔽的位置。交叉熵损失仅在被遮蔽的位置上计算，而未被遮蔽的位置和打包序列边界位置则被赋予 IGNORE_INDEX。

Listing 2: Masked diffusion corruption.

```
mask_ratio = torch.rand(1).clamp(1 / 500, 1 - 1 / 500)
mask = torch.rand_like(input_ids.float()) < mask_ratio

labels = input_ids.clone()
input_ids[mask] = mask_token_id
labels[input_ids != mask_token_id] = IGNORE_INDEX
```

让 M 表示被遮罩且平移有效的位置集合。掩码去噪损失为

$$\mathcal{L}_{\text{mdm}} = \frac{1}{|M|} \sum_{i \in M} \text{CE}(p_{\theta}(\cdot | \tilde{x})_i, x_i), \quad (5)$$

其中 $\tilde{x}$ 是受损的输入序列。在实现中，token 损失会在有效的掩码位置上求和，并按有效掩码 token 的数量进行归一化。

B.4 表示对齐

对于表示对齐，我们通过深拷贝初始化的 AR 模型来构建一个冻结的教师模型。教师模型处于评估模式，且所有教师参数都被冻结。在训练过程中，教师在因果注意力下处理干净序列，而学生在双向注意力下处理掩码序列。教师特征在 `torch.no_grad()` 下计算。本节实现了公式 (2) 中的对齐损失，包括纳入哪些隐藏状态和 token 位置。

我们对模型返回的隐藏状态元组进行对齐，包括嵌入隐藏状态、块输出以及最终的后归一化隐藏状态。默认情况下，所有返回的隐藏状态都会对齐。层消融会选择该隐藏状态元组中连续的三分之一。对齐仅应用于掩码和 shift-valid 位置，匹配那些对去噪损失有贡献的位置。

对于余弦对齐，隐藏状态沿特征维度进行归一化，损失计算为 1 减去平均余弦相似度：

$$\mathcal{L}_{\text{align}} = 1 - \frac{1}{|\mathcal{H}|} \sum_{h \in \mathcal{H}} \frac{1}{|M|} \sum_{i \in M} \left\langle \frac{h_{\text{D},i}}{\|h_{\text{D},i}\|_2}, \frac{\text{sg}(h_{\text{AR},i})}{\|\text{sg}(h_{\text{AR},i})\|_2} \right\rangle, \quad (6)$$

其中， $\mathcal{H}$ 是所选的隐藏状态集合， M 是掩码和移位有效位置集合， $\text{sg}(\cdot)$ 表示停止梯度。

Listing 3: Layer-wise representation alignment.

```
with torch.no_grad():
    teacher_outputs = teacher(
        input_ids=clean_input_ids,
        is_causal=True,
        output_hidden_states=True,
```

```

    )

    student_outputs = student(
        input_ids=masked_input_ids,
        is_causal=False,
        output_hidden_states=True,
    )

    loss_mask = labels != IGNORE_INDEX
    repr_loss = cosine_distance(
        student_outputs.hidden_states,
        teacher_outputs.hidden_states,
        loss_mask=loss_mask,
    )

    loss = mdm_loss + path_loss + lambda_repr * repr_loss

```

默认对齐权重为 $\lambda_{\text{repr}} = 10$ 。除非另有说明，所有对齐模型都使用余弦对齐，作用于所有选定的隐藏状态。

B.5 路径规划损失

所有 DLM 运行，包括基线模型和表示对齐模型，都包含相同的路径规划辅助损失。因此，我们将该损失视为默认 DLM 训练方案的一部分，而不是作为单独的方法特定组件。这确保了比较能够隔离 REPR-ALIGN 的效果。该项在第 4.1 节中的基线模型和对齐模型中都包含，因此主要比较隔离的是 $\mathcal{L}_{\text{align}}$

对于基于 Qwen3 的运行，路径规划损失通过分离的模型置信度对掩码标记交叉熵进行重加权：

$$\mathcal{L}_{\text{path}} = \frac{1}{|M|} \sum_{i \in M} \exp(-\ell_i)_{\text{sg}} \ell_i, \quad (7)$$

其中 ℓ_i 是掩码位置 i 处的词元级交叉熵损失，置信度权重是停止梯度的。总训练损失为

$$\mathcal{L} = \mathcal{L}_{\text{mdm}} + \mathcal{L}_{\text{path}} + \lambda_{\text{repr}} \mathcal{L}_{\text{align}}. \quad (8)$$

对于基线 DLM 转换，省略表示对齐项：

$$\mathcal{L}_{\text{baseline}} = \mathcal{L}_{\text{mdm}} + \mathcal{L}_{\text{path}}. \quad (9)$$

B.6 优化

所有模型都使用 AdamW 进行优化。除非另有说明，我们在基线和表示对齐运行中使用相同的优化配置。该优化协议是第 4.2 节中使用的固定预算设置。

B.7 解码与评估

我们在 HumanEval [Chen et al., 2021]、MBPP [Austin et al., 2021b] 以及来自 EvalPlus [Liu et al., 2023] 的 HumanEval+/MBPP+ 变体上评估代码生成。HumanEval 使用该基准中的标准提示。MBPP 使用任务描述、前三个测试，并以一个 Python 代码块结尾。所有评估均为零样本。该评估协议构成了第 4.2 节中的主要比较以及第 4.3 节中的消融实验的基础。

对于每个问题，我们生成 10 个样本，并使用标准的代码评估流程计算基于执行的 pass@1 和 pass@10。所有比较的方法都使用相同的解码配置。

P2 采样器保持提示词 token 不变，并迭代地对低置信度的可变位置重新加掩码。在每一步中，模型都会预测完整序列，对可变位置进行采样，然后根据采样计划对一部分置信度最低的生成 token 重新加掩码。

Listing 4: Evaluation command template.

```

accelerate launch --num_processes 4 eval.py \
--model custom_coder \
--model_args "pretrained=<checkpoint>,max_new_tokens=128,steps=128,temperature=0.8,alg=p2" \

```

表 5：默认优化配置。

Setting	Value
Optimizer	AdamW
Learning rate	3×10^{-4}
Adam betas	(0.9, 0.95)
Adam epsilon	10^{-8}
Weight decay	0.01
Parameter groups	single group for all trainable parameters
LR schedule	cosine decay
Warmup ratio	0.001
Minimum learning rate	3×10^{-6}
Gradient clipping	1.0
Precision	bfloat16
Maximum sequence length	4096
Per-device batch size	6
Gradient accumulation	1
Global batch size	96 sequences
Number of GPUs	16
Parallelism	DDP
Attention backend	FlashAttention-2
Gradient checkpointing	disabled
FSDP / DeepSpeed	disabled

Table 6: Default decoding and evaluation configuration.

Setting	Value
Benchmarks	HumanEval, HumanEval+, MBPP, MBPP+
Prompting	zero-shot
Samples per problem	10
Metric	execution-based pass@1/pass@10
Sampler	P2-self, alg=p2
Sampling steps	128
Maximum new tokens	128
Temperature	0.8
Top- k	200
Algorithm temperature	0.5

```
--tasks humaneval --num_fewshot 0 --batch_size 10 \
--output_path evals_results/humaneval-ns0 --log_samples \
--confirm_run_unsafe_code
```

B.8 消融协议

除非另有说明，所有消融实验都使用相同的 AR→DLM 转换流程。特别地，模型都从同一个 AR 检查点初始化，使用相同的掩码去噪目标和路径规划损失进行训练，并在相同的解码配置下进行评估。每个消融实验只改变所列因素。这些协议对应于第 4.3 节中的消融结果。

对于对齐度量消融，L2 对齐使用学生和教师隐藏状态之间的均方误差，而余弦对齐则沿特征维度对隐藏状态进行归一化，并匹配它们的方向。对于层消融，我们将隐藏状态元组划分为三个连续的组，并且每次只对其中一组应用表示损失。默认设置使用余弦距离对所有隐藏状态进行对齐，并且 $\lambda_{\text{repr}} = 10$ 。

B.9 冻结协议

为了测试 AR→DLM 转换是否需要更新整个网络，我们在表示对齐训练期间冻结选定的参数块。冻结通过对参数名称进行不区分大小写的子字符串匹配来实现。在主要的冻结变体中，名称包含 `embed.tokens`、`lm_head` 或 `mlp` 的参数被冻结。注意力层和归一化层保持可训练。该协议支持第 4.2 节中的效率结果。

表7：消融方案。

Ablation	Variants	Changed factor
Alignment metric	L2, cosine	representation loss
Alignment weight	1, 5, 10, 20	λ_{repr}
Aligned layers	lower, middle, upper, all	selected hidden states
Freezing	none, embeddings/LM head/MLP	trainable parameter blocks
Data size	full, reduced	training stream size

表 8：冻结配置。

Variant	Frozen parameters	Trainable parameters
No freezing	none	all parameters
Embedding/MLP freezing	<code>embed_tokens</code> , <code>lm_head</code> , <code>mlp</code>	attention and normalization layers

该冻结协议旨在保留大部分预训练的特征和前馈计算，同时允许注意力机制和归一化统计适应双向去噪。

C 局限性

我们的研究仅限于在 Qwen3 仅解码器检查点和代码生成基准上进行同架构 AR→DLM 转换。我们报告的收益可能无法原样迁移到其他模型家族、模态或下游任务，而且该方法仍依赖于获得一个强大的预训练 AR 教师以及大量训练算力。

D 更广泛的影响

这项工作可以降低训练具有竞争力的扩散语言模型的计算门槛，这可能使高效生成研究更易于开展。将预训练语言模型更低成本地转换过来，也可能让代码合成及其他生成能力更容易被规模化用于有害或欺骗性用途，因此部署应遵循常规的模型管理实践。由于我们的贡献是一种训练方法，而不是发布的模型或数据集，我们不建议单独的发布限制。

NeurIPS 论文检查清单

1. 权利要求

问题：摘要和引言中提出的主要主张是否准确反映了论文的贡献和范围？

答案：[是]

理由：摘要和引言准确描述了论文的范围：在同一架构下进行 AR→DLM 转换，并采用逐层表示对齐，在 Qwen3 检查点和代码生成基准上进行了评估。这些主张与第 4.2 和 4.3 节报告的实验和消融结果一致。

指南：

- 答案 [N/A] 表示摘要和引言未包含论文中提出的主张。
- 摘要和/或引言应清楚陈述所提出的主张，包括论文中的贡献以及重要的假设和局限性。对此问题回答 [No] 或 [N/A] 不会给评审留下良好印象。
- 所提出的主张应与理论和实验结果相一致，并反映这些结果可推广到其他设置的程度。
- 可以将理想目标作为动机纳入，只要明确这些目标并未被论文实现。

2. 限制

问题：论文是否讨论了作者所做工作的局限性？

答案：[是]

理由：修订后的论文现在包含了专门的 C 节。它清楚地说明了主要范围限制：同架构的 Qwen3 转换、代码生成基准、对强大预训练 AR 教师的依赖，以及大量的训练计算量。

指南：

- 答案 [N/A] 表示论文没有局限性，而答案 [No] 表示论文存在局限性，但这些局限性并未在论文中讨论。
- 鼓励作者在论文中单独创建一个“局限性”部分。
- 论文应指出任何强假设，以及结果对这些假设被违反时的稳健性如何（例如，独立性假设、无噪声设置、模型设定正确、渐近近似仅在局部成立）。作者应反思这些假设在实践中可能如何被违反，以及其影响是什么。
- 作者应反思所提出主张的适用范围，例如，该方法是否仅在少量数据集上或仅进行了少数次运行测试。一般而言，经验结果往往依赖于隐含假设，这些假设应当被明确说明。
- 作者应反思影响该方法性能的因素。例如，当图像分辨率较低或图像在低光照条件下拍摄时，人脸识别算法可能表现不佳。或者，语音转文字系统可能无法可靠地用于在线课程的字幕，因为它不能处理专业术语。
- 作者应讨论所提出算法的计算效率以及它们如何随数据集规模扩展。
- 如适用，作者应讨论其方法在解决隐私和公平性问题方面的可能局限。
- 尽管作者可能担心，若完全坦诚地说明局限性，审稿人会以此作为拒稿理由，但更糟糕的结果可能是审稿人发现了论文中未被承认的局限性。作者应充分运用自己的判断，并认识到，支持透明性的个人行动在形成维护社区完整性的规范方面发挥着重要作用。审稿人将被特别要求不要因对局限性的坦诚而进行惩罚。

3. 理论假设与证明

问题：对于每个理论结果，论文是否提供了全部假设以及完整（且正确）的证明？

答案：[N/A]

理由：本文不包含新的定理、引理或形式化证明；相反，它展示了一种经验性方法，并给出了明确的方程和实现细节。

指南：

- 答案 [N/A] 表示该论文不包含理论结果。
- 论文中的所有定理、公式和证明都应编号并相互引用。
- 所有假设都应在任何定理的表述中清楚地说明或加以引用。
- 证明可以出现在主论文中，也可以出现在补充材料中，但如果出现在补充材料中，建议作者提供一个简短的证明思路以帮助理解。
- 反之，论文主体中提供的任何非正式证明都应辅以附录或补充材料中提供的正式证明。
- 证明所依赖的定理和引理应被适当引用。

4. 实验结果的可重复性

问题：本文是否充分披露了重现论文主要实验结果所需的全部信息，且该披露程度足以影响论文的主要主张和/或结论（无论是否提供代码和数据）？

答案：[是]

理由：论文在 B 节和 4.1 节中明确说明了模型家族、检查点来源、训练数据、预处理、优化超参数、解码设置以及消融实验协议。这些细节足以让其他团队在原则上复现主要实验。

指南：

- 答案 [N/A] 表示论文不包含实验。
- 如果论文包含实验，对于这个问题回答 [No] 不会被审稿人看好：无论是否提供代码和数据，使论文可复现都很重要。
- 如果贡献是一个数据集和/或模型，作者应描述为使其结果可复现或可验证所采取的步骤。
- 根据贡献的不同，可复现性可以通过多种方式实现。例如，如果贡献是一种新颖的架构，完整描述该架构可能就足够了；或者如果贡献是一个特定模型及其实证评估，则可能需要让他人能够使用相同的数据集复现该模型，或提供对该模型的访问。一般来说，公开代码和数据通常是实现这一点的一种好方法，但也可以通过提供如何复现结果的详细说明、访问托管模型（例如在大语言模型的情况下）、发布模型检查点，或其他适合所进行研究的方式来提供可复现性。
- 虽然 NeurIPS 不要求公开代码，但该会议要求所有投稿都提供某种合理的可复现路径，具体可能取决于贡献的性质。例如：(a) 如果贡献主要是一种新算法，论文应清楚说明如何复现该算法。(b) 如果贡献主要是一个新的模型架构，论文应清晰、完整地描述该架构。(c) 如果贡献是一个新模型（例如大语言模型），则应当提供一种访问该模型以复现结果的方法，或者提供一种复现该模型的方法（例如，使用开源数据集或关于如何构建该数据集的说明）。

(d) 我们认识到, 在某些情况下, 可重复性可能比较棘手, 在这种情况下, 作者可以说明他们为实现可重复性所采用的具体方式。对于闭源模型, 可能会以某种方式限制对模型的访问(例如, 仅限注册用户), 但其他研究人员仍应能够通过某种途径复现或验证结果。

5. 数据和代码的开放获取

问题: 论文是否对数据和代码提供了开放获取, 并在补充材料中给出了足够的说明, 以便忠实地复现主要实验结果?

答案:[否]

正当性说明: 该手稿给出了详细的复现说明, 但尚未公开发布本文所使用的训练数据或转换后的模型检查点。因此, 可复现性已有记录, 但论文本身并未提供对全部代码/数据资源的开放访问。

指南:

- 答案 [N/A] 表示该论文不包含需要代码的实验。 • 更多细节请参见 NeurIPS 代码和数据提交指南 (<https://neurips.cc/public/guides/CodeSubmissionPolicy>)。 • 虽然我们鼓励公开代码和数据, 但我们理解这可能无法实现, 因此 [No] 也是可以接受的答案。论文不能仅仅因为不包含代码而被拒稿, 除非代码是其贡献的核心内容(例如, 一个新的开源基准)。 • 说明应包含复现结果所需的确切命令和环境。更多细节请参见 NeurIPS 代码和数据提交指南 (<https://neurips.cc/public/guides/CodeSubmissionPolicy>)。 • 作者应提供数据访问和准备的说明, 包括如何访问原始数据、预处理数据、中间数据和生成数据等。 • 作者应提供复现新提出方法和基线所有实验结果的脚本。若只能复现部分实验, 应说明脚本中省略了哪些实验以及原因。 • 在提交时, 为了保持匿名性, 作者应发布匿名版本(如适用)。 • 建议在补充材料(附在论文后)中提供尽可能多的信息, 但也允许包含指向数据和代码的 URL。

6. 实验设置/细节

问题: 论文是否明确说明了理解结果所需的所有训练和测试细节(例如, 数据划分、超参数、如何选择它们、优化器类型)?

答案:[是]

理由: 核心论文和附录明确规定了模型家族、训练语料、预处理、优化超参数、解码配置和评估协议。消融实验附录也记录了每项研究中所改变的因素。

指南:

- 答案 [N/A] 表示该论文不包含实验。 • 实验设置应在论文主体中呈现, 并达到理解结果及其意义所必需的详细程度。 • 完整细节可以随代码提供, 或放在附录中, 或作为补充材料提供。

7. 实验统计显著性

问题: 论文是否恰当地且正确地报告了误差条, 或者是否提供了关于实验统计显著性的其他适当信息?

答案:[否]

理由：所报告的基准测试表格和图仅给出了点估计；稿件未包含主结果的误差棒、置信区间或多随机种子显著性检验。

指南：

- 答案 [N/A] 表示论文不包含实验。
- 如果结果附有误差条、置信区间或统计显著性检验，作者应回答 [Yes]，至少对于支持论文主要结论的实验应如此。
- 误差条所反映的变异因素应清楚说明（例如，训练/测试划分、初始化、某个参数的随机抽样，或给定实验条件下的整体运行）。
- 应解释误差条的计算方法（闭式公式、调用库函数、bootstrap 等）。
- 应给出所做的假设（例如，误差服从正态分布）。
- 应明确误差条表示的是标准差还是均值的标准误。
- 可以报告 1-sigma 误差条，但应予以说明。如果未验证误差正态性假设，作者最好报告 2-sigma 误差条，而不是声称存在 96% 置信区间。
- 对于非对称分布，作者应注意不要在表格或图中显示对称误差条，否则会得到超出范围的结果（例如，负的错误率）。
- 如果在表格或图中报告了误差条，作者应在正文中说明其计算方法，并在正文中引用相应的图或表。

8. 实验计算资源

问题：对于每个实验，论文是否提供了足够的信息，说明重现实验所需的计算机资源（计算工作节点的类型、内存、执行时间）？

答案：[否]

正当性：附录报告称训练使用了 16 张 GPU 和 DDP，并给出了批次/优化器设置，但尚未说明主实验运行所用的加速器型号、内存占用或实际墙钟时间。

指南：

- 答案 [N/A] 表示该论文不包含实验。
- 论文应说明计算工作节点的类型是 CPU 还是 GPU、内部集群还是云服务提供商，并包括相关的内存和存储信息。
- 论文应提供每个单独实验运行所需的计算量，并估算总计算量。
- 论文应披露完整研究项目是否需要比论文中报告的实验更多的计算资源（例如，未写入论文的预备实验或失败实验）。

9. 道德准则

问题：论文中进行的研究在各个方面都符合 NeurIPS 伦理准则 <https://neurips.cc/public/EthicsGuidelines> 吗？

答案：[是]

理由：该研究使用了公开或已适当授权的模型和基准资产，不涉及任何人类受试者或敏感数据收集，并且未发现任何偏离 NeurIPS 伦理准则的情况。该论文的研究行为符合所写明的伦理指南。

指南：

- 答案 [N/A] 表示作者尚未审阅 NeurIPS 代码伦理规范。

- 如果作者回答[否]，他们应说明需要偏离《道德规范》的特殊情况。
- 作者应确保保持匿名（例如，如果其所在司法管辖区的法律或法规有特殊考虑）。

10. 更广泛的影响

问题：这篇论文是否同时讨论了所执行工作的潜在积极社会影响和消极社会影响？

答案：[是]

理由说明：修订后的论文现在包含一个简短的更广泛影响部分，讨论了计算成本降低带来的收益，以及生成代码能力因更便宜的扩展而带来的风险。它还说明，本文并不建议采用受限发布或使用限制，因为它是一种训练方法，而不是一个已发布的模型。

指南：

- 答案 [N/A] 表示该工作没有社会影响。
- 如果作者回答 [N/A] 或 [No]，他们应解释为什么其工作没有社会影响，或为什么论文未涉及社会影响。
- 负面社会影响的例子包括潜在的恶意或非预期用途（例如，虚假信息、生成虚假账号、监控）、公平性考量（例如，部署可能做出不公平地影响特定群体的决策的技术）、隐私考量以及安全考量。
- 会议预计许多论文将是基础研究，并不针对特定应用，更不用说部署。然而，如果存在通向任何负面应用的直接路径，作者应指出这一点。例如，指出生成式模型质量的提升可能被用于生成用于虚假信息传播的深度伪造（Deepfakes）是合理的。另一方面，没有必要指出一种用于优化神经网络的通用算法会使人们能够更快地训练生成深度伪造的模型。
- 作者应考虑在技术按预期使用且正常运行时可能产生的危害、在技术按预期使用但给出错误结果时可能产生的危害，以及因技术被（有意或无意地）误用而引发的危害。
- 如果存在负面社会影响，作者还可以讨论可能的缓解策略（例如，对模型进行受限发布、在攻击之外提供防御、监测误用的机制、监测系统如何随时间从反馈中学习的机制、提高机器学习的效率和可及性）。

11. 保障措施

问题：本文是否描述了为负责任地发布具有高误用风险的数据或模型（例如，预训练语言模型、图像生成器或抓取的数据集）而采取的保障措施？

答案：[N/A]

理由：该论文并未发布具有更高滥用风险的新模型或数据集，因此这里没有需要单独保护的发布机制。若未来增加检查点发布，应同时附上一份专门的安全保障声明。

指南：

- 答案 [N/A] 表示该论文不存在此类风险。
- 对于存在较高误用或双重用途风险的已发布模型，应在发布时配备必要的安全保障措施，以便对模型进行受控使用，例如要求用户遵守使用指南或对访问模型施加限制，或实施安全过滤器。
- 从互联网抓取的数据集可能带来安全风险。作者应说明他们如何避免发布不安全的图像。
- 我们认识到，提供有效的保障措施具有挑战性，而且许多论文并不要求这样做，但我们鼓励作者将这一点纳入考虑，并尽最大善意努力。

12. 现有资产许可证

问题：论文中使用的资产（例如代码、数据、模型）的创建者或原始所有者是否得到了适当致谢，并且其许可和使用条款是否被明确提及并得到妥善遵守？

答案：[是]

理由：论文现在已说明主要资产的相关许可证/条款：Qwen3 检查点（Apache 2.0）、Nemotron-SFT-Code（NVIDIA 模型训练数据协议）、HumanEval（MIT）、MBPP（CC BY 4.0），以及 EvalPlus HumanEval+/MBPP+（Apache 2.0）。每个资产也都在参考文献中引用。

指南：

- 答案 [N/A] 表示该论文未使用现有资产。
- 作者应引用生成该代码包或数据集的原始论文。
- 作者应说明使用了资产的哪个版本，并在可能的情况下提供 URL。
- 每个资产都应包含许可证名称（例如，CC-BY 4.0）。
- 对于从特定来源（例如网站）抓取的数据，应提供该来源的版权和服务条款。
- 如果资产已发布，应提供包中的许可证、版权信息和使用条款。对于流行的数据集，paperswithcode.com/datasets 已为某些数据集整理了许可证。其许可指南可帮助确定数据集的许可证。
- 对于重新打包的现有数据集，应同时提供原始许可证以及衍生资产的许可证（如果已更改）。
- 如果这些信息无法在网上获得，建议作者联系该资产的创建者。

13. 新资产

问题：论文中引入的新资产是否有充分的文档说明，并且是否提供了与这些资产一同的文档？

答案：[N/A]

理由：该稿件以当前形式并未引入一个新发布的数据集、基准或模型包。

指南：

- 答案 [N/A] 表示该论文没有发布新的资产。
- 研究人员应通过结构化模板在提交中说明数据集/代码/模型的详细信息。这包括关于训练、许可证、限制等方面的细节。
- 论文应讨论是否以及如何从其资产所使用的人员那里获得了同意。
- 在提交时，请记得对你的资产进行匿名化（如果适用）。你可以创建一个匿名 URL，或包含一个匿名的 zip 文件。

14. 众包与人类受试者研究

问题：对于众包实验和涉及人类受试者的研究，论文是否包含发给参与者的完整指令文本以及截图（如适用），以及关于报酬（如有）的详细信息？

答案：[N/A]

理由：该论文不涉及众包或人类受试者实验。

指南：

- 答案 [N/A] 表示该论文既不涉及众包，也不涉及人类受试者研究。
- 将此信息包含在补充材料中是可以的，但如果论文的主要贡献涉及人类受试者，则应尽可能在正文中提供尽可能多的细节。

- 根据 NeurIPS 伦理准则，从事数据收集、整理或其他劳动的工人应至少获得数据收集者所在国家的最低工资。

15. 涉及人类受试者研究的机构审查委员会（IRB）批准或同等批准

问题：论文是否描述了研究参与者可能面临的风险、这些风险是否已向受试者披露，以及是否已获得机构审查委员会（IRB）批准（或根据您所在国家或机构要求的等效批准/审查）？

答案：[N/A]

理由：该论文不涉及人类受试者，因此不适用 IRB 批准或等效审查。

指南：

- 答案 [N/A] 表示该论文不涉及众包，也不涉及人类受试者研究。
- 根据开展研究所在的国家，任何人类受试者研究都可能需要 IRB 批准（或等同审批）。如果你获得了 IRB 批准，应在论文中明确说明。
- 我们认识到，这方面的程序在不同机构和地点之间可能有很大差异，我们希望作者遵守 NeurIPS 伦理准则及其所在机构的相关指南。
- 对于初次提交，请勿包含任何会破坏匿名性的信息（如适用），例如进行审查的机构。

16. LLM 使用声明

问题：如果 LLM 的使用是本研究核心方法中一个重要、原创或非标准的组成部分，论文是否描述了其使用情况？请注意，如果 LLM 仅用于写作、编辑或格式化用途，并且 *not* 不影响研究的核心方法、科学严谨性或原创性，则无需声明。

答案：[是]

理由：核心方法和评估显然是围绕 LLM 检查点和基准构建的，尤其是基于 Qwen3 的 AR/DLM 转换。论文在方法和实验部分都记录了这一点。

指南：

- 答案 [N/A] 表示本研究中的核心方法开发并未将 LLM 作为任何重要、原创或非标准组件。
- 请参考 NeurIPS 手册中的我们的 LLM 政策，以了解哪些内容应该或不应该被描述。